한국정보보호학회
Korea Institute of Information Security & Cryptology

SHAP 기반 Feature Importance를 이용한 IDS Feature Reduction과 탐지 성능 영향 분석

2025. 05. 07

광운대학교 컴퓨터공학과 우나륜

KWANGWOON UNIVERSITY

CnCS Lab
Cryptography & Cyber Security

CONTENTS

01 연구 배경

- 연구 배경 및 동기
- 배경지식
- Research Questions

02 실험 설계

- 실험 파이프라인
- 실험 데이터셋 및 모델
- 평가 지표

03 실험 결과 및 결론

- 모델별 결과 해석
- Response to RQs
- 결론 및 향후연구

연구 배경

01

- 연구 배경 및 동기
- 배경지식
- Research Questions

실험 설계

실험 결과 및 결론

연구 배경 및 동기

과연 모든 feature가 공격 탐지 및 분류에 필요한가?

침입탐지시스템(IDS)의 현주소

- APT 등 네트워크 공격 유형의 다양화
- 자동화된 공격 탐지와 트래픽 패턴 학습을 위해 RF, CNN 등 머신러닝 기법 활용
- Zero Trust 보안 모델 확산에 따른 IDS 등 보안 솔루션 적용 증가

문제 인식

- **설명력 부재** : 모델이 black-box 형태로 동작함에 따라 공격으로 판단한 근거를 설명하기 어려움
- **비효율적 연산** : 고차원 feature가 학습 시간을 증가시키고 과도한 연산 자원 소모

Black-box 문제[1]

Hidden Layer

- ✓ 모델 결과에 대한 신뢰도 감소
- ✓ 모델 운영 조정의 어려움
- ✓ 모델 편향 결과 발견 어려움

1. 입력 데이터
수치, 텍스트, 이미지 등

Visible Layer

입력

AI Model

출력

3. 출력 결과
고양이 95% 강아지 4% 새 1%

2. 복잡한 알고리즘
딥러닝 등 고도화된 모델
고급 언어 처리, 콘텐츠 생성 등 고도화된 작업 수행

KWANGWOON UNIVERSITY
CnCS Lab

설명가능한 인공지능 (eXplainable AI, XAI)[2]

① 필요성

- Black-box 모델의 불투명성 해결
- 모델 결과에 대한 영향 및 잠재적 편향을 설명
- 모델에 대한 신뢰와 확신 구축

② 정의

머신 러닝 알고리즘이 생성한 결과를
인간이 이해하고 신뢰할 수 있도록하는 일련의 방법

③ 주요 기법

④ 기대 효과와 이점

- 모델의 신뢰성과 투명성을 갖춤
- 모델 거버넌스에 대한 위험 및 비용 완화

SHapley Additive exPlanations (SHAP)[3]

학습에 사용된 각 feature가 모델 예측에 기여한 정도를 정량적으로 계산하는 XAI 기법 중 하나

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!\,(|F| - |S| - 1)!}{|F|!} \left[f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S) \right]$$

수식 1. Shapley value 계산식

수식	설명	수식	설명
i	관심 있는 변수(=feature)	F	전체 feature 집합
ϕ_i	특정 feature i의 shapley value	S	i가 제외된 F의 부분 집합
$f_{S \cup \{i\}}(x_{S \cup \{i\}})$	S에 i까지 포함했을 때의 모델 예측값	$f_S(x_S)$	S만 가지고 모델이 예측한 값

모든 feature 조합에 대해 특정 feature i가 있을 때와 없을 때 예측값의 차이를 계산하고,
이를 평균하여 기여도 산출

KWANGWOON UNIVERSITY
CnCS Lab Cryptography & Cyber Security

Research Questions

SHAP 기법을 사용하여 중요도가 높은 feature를 식별하여 모델의 이상탐지 성능 변화 분석

RQ1 **전체 탐지 성능 변화**

Feature reduction 이후에도 IDS 모델의 전체 탐지 성능이 어느 수준까지 유지되거나 향상될 수 있는가?

RQ2 **소수 클래스 영향 분석**

Feature reduction 과정에서 데이터 수가 극히 적은 소수 클래스(Minority class)의 탐지 성능은 어떻게 변화하는가?

- 실험 파이프라인
- 실험 데이터셋 및 모델
- 평가 지표

연구 배경

실험 설계

02

실험 결과 및 결론

전체 실험 절차

데이터셋 준비 → 데이터 전처리 → 모델 학습 → 다음 단계에 사용할 feature 선택

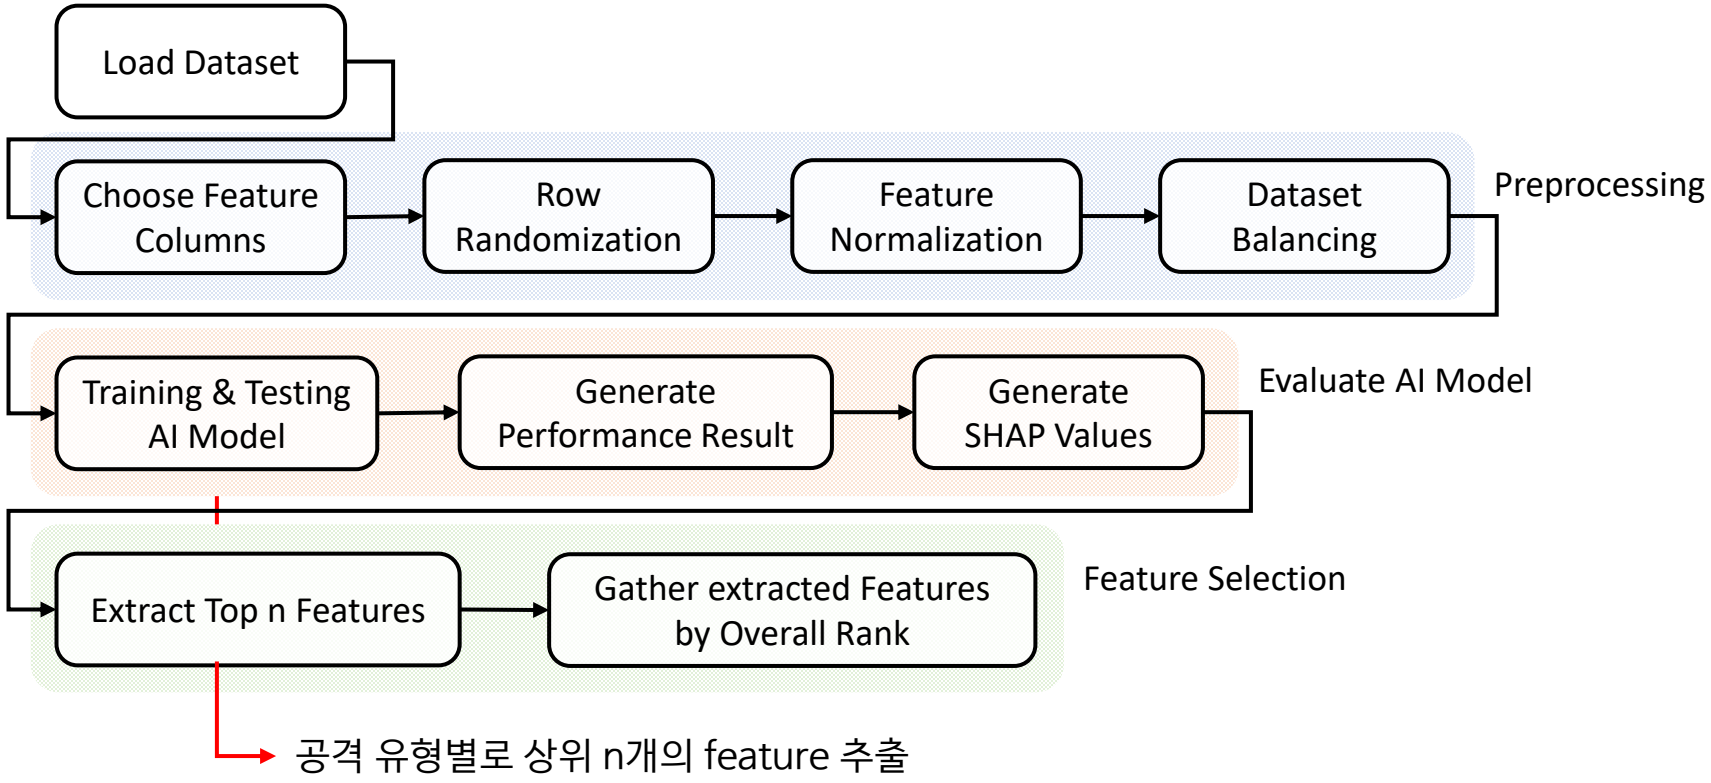

단계적 feature reduction

이전 단계에서 얻은 feature subset으로 학습하며 성능 변화를 관찰

Phase 0 (P0)

- 데이터셋의 모든 feature 사용
- 유형별 SHAP 값이 가장 높은 상위 20개 feature를 추출하여 subset 구성

Phase 1 (P1)

- P0에서 얻은 feature subset을 사용하여 학습
- 이전과 같이 상위 10개의 feature 추출하여 subset 구성

Phase 2 (P2)

- P1에서 얻은 feature subset을 사용하여 학습
- 상위 5개의 feature 추출하여 subset 구성

Phase 3 (P3)

- P2에서 얻은 feature subset을 사용하여 학습

KWANGWOON UNIVERSITY
CnCS Lab Cryptography & Cyber Security

실험 데이터셋 및 모델

4개의 전통적/최신 데이터셋과 6개의 다양한 분류 모델 사용

데이터셋		
이름	(Feature, class)	설명
KDD99	(118, 22)	전통적 IDS 벤치마크
UNSW-NB15	(38, 10)	최신 공격, 현실적 트래픽
CSE-CIC-IDS2018	(79, 7)	다양한 최신 공격 포함
InSDN	(79, 14)	SDN 환경 기반 데이터셋

모델	
이름	설명
Random Forest (RF)	여러 결정 트리를 결합한 앙상블 기반 분류 모델
Decision Tree (DT)	조건 분기로 데이터를 분류하는 트리 구조 모델
Support Vector Machine (SVM)	데이터를 구분하는 최적의 경계면을 찾는 분류 모델
CNN	공간적 패턴을 학습하는 딥러닝 모델
ANN	가장 기본적인 신경망 모델
KNN	데이터간 거리를 기반으로 분류하는 유사도 기반 모델

평가 지표[4, 5]

① 정확도

모델이 전체 문제 중에서 정답을 맞춘 비율

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

② 정밀도

모델이 positive로 예측한 것들 중 실제 positive인 비율

$$Prec = \frac{TP}{TP + FP}$$

③ 재현율

실제로 positive인 것들 중에서 모델이 positive로 예측한 비율

$$Rec = \frac{TP}{TP + FN}$$

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

T(True): 예측한 것이 **정답**
F(False): 예측한 것이 **오답**
P(Positive): 모델이 **positive**라고 **예측**
N(Negative): 모델이 **negative**라고 **예측**

평가 지표[4, 5]

④ 조화 평균

정밀도와 재현율은 종종 상충 관계에 있으므로 둘의 조화 평균을 주로 사용

$$F1 - Score = \frac{2 * Prec * Rec}{Prec + Rec}$$

② 정밀도

모델이 positive로 예측한 것들 중 실제 positive인 비율

$$Prec = \frac{TP}{TP + FP}$$

③ 재현율

실제로 positive인 것들 중에서 모델이 positive로 예측한 비율

$$Rec = \frac{TP}{TP + FN}$$

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

T(True): 예측한 것이 **정답**
F(False): 예측한 것이 **오답**
P(Positive): 모델이 **positive**라고 **예측**
N(Negative): 모델이 **negative**라고 **예측**

- 모델별 결과 해석
- Response to RQs
- 결론 및 향후 연구

연구 배경

실험 설계

실험 결과 및 결론

03

Random Forest – KDD99

모델별 결과 분석 (1)

Phase 0 (P0)

	Prec.	Rec.	F1
back*	1	0.998487	0.999243
buffer_overflow*	0.875	0.777778	0.823529
ftp_write*	0	0	0
guess_passwd*	1	0.9375	0.967742
imap*	1	1	1
ipsweep	0.994595	0.983957	0.989247
land*	1	1	1
loadmodule	0	0	0
multihop*	1	0.5	0.666667
neptune*	1	1	1
nmap	0.971014	0.971014	0.971014
perl*	1	1	1
phf*	1	1	1
pod*	1	0.987342	0.993631
portsweep	1	0.99359	0.996785
rootkit*	0	0	0
satan	1	0.991614	0.995789
spy*	1	0.999933	0.999967
teardrop*	0	0	0
warezclient*	1	1	1
warezmaster	0.891496	0.993464	0.939722
normal	0.999074	0.998732	0.998903
accuracy			0.998884
macro avg	0.805963	0.778791	0.788284
weighted avg	0.998797	0.998884	0.998823

Phase 3 (P3)

	Prec.	Rec.	F1
back*	1	0.9984	0.9992
buffer_overflow*	0.875	0.7777	0.8235
ftp_write*	0	0	0
guess_passwd*	1	0.9375	0.9677
imap*	1	1	1
ipsweep	0.9945	0.9812	0.9878
land*	1	1	1
loadmodule	1▲1	0.333▲0.333	0.5▲0.5
multihop*	1	0.5	0.6666
neptune*	1	1	1
nmap	0.9571(▼0.138)	0.971*	0.964
perl*	1	1	1
phf*	1	1	1
pod*	1	0.9873	0.9936
portsweep	1*	0.9903	0.9951
rootkit*	0	0	0
satan	1*	0.9895	0.9947
spy*	1	0.9999	0.9999
teardrop*	0	0	0
warezclient*	1	1	1
warezmaster	0.9074▲0.159	0.9934*	0.9485(▲0.009)
normal	0.999	0.9989	0.9989
accuracy			0.9989
macro avg	0.8515 (▲0.0456)	0.7935 (▲0.0147)	0.8109 (▲0.0236)
weighted avg	0.9988	0.9989	0.9988

- Feature 개수 : 118 〉 29
- Majority/Minority class에 대해 대부분 높은 탐지율 달성

- **Phase 0:** ftp_write(2), loadmodule(3), rookit(3), teardrop(1)에서 탐지 실패
- **Phase 3:** loadmodule 탐지 성공

- 전체적인 성능 소폭 상승

*표시는 P0 결과와 소숫점 6째 자리까지 성능이 동일함.

KWANGWOON UNIVERSITY
CnCS Lab

Random Forest – KDD99

Phase 0 (P0)

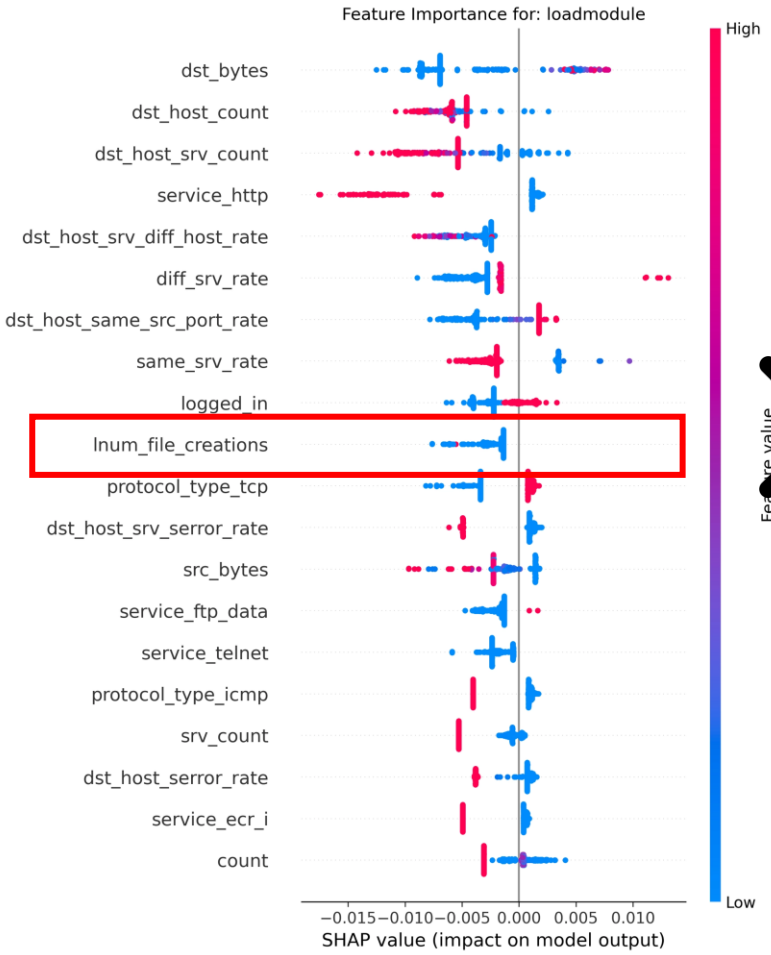

Phase 3 (P3)

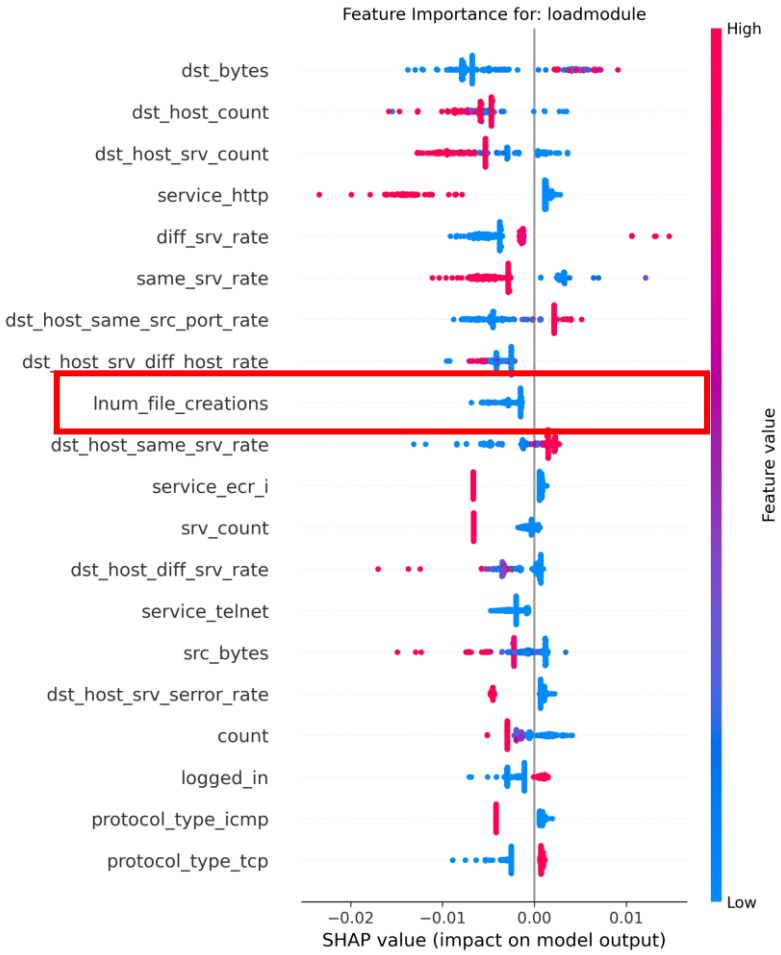

- **Loadmodule의 SHAP 분포 비교**

  시스템의 커널 모듈/프로그램 로딩 기능을 악용해 일반 사용자가 관리자 권한을 얻으려는 공격

- Feature의 수가 줄어듦에 따라 **분산되어 있던 중요도가 핵심 feature에 강조**되며 탐지에 기여한 것으로 분석됨

KWANGWOON UNIVERSITY
CnCS Lab

Random Forest – Overview

CIC2018에서 phase 진행에 따라 0.0003 ~ 0.0025 사이의 recall 하락 발생함
하지만 이외엔 점진적으로 모든 평가 지표에 대해서 상승세를 보임

Random Forest 모델에서 데이터셋별 phase에 따른 accuracy 변화

	P0	P1	P2	P3
KDD99	0.9988	0.999_{52}	0.999_{48}	$\mathbf{0.9989_{37}}$
UNSW-NB15	0.8923	0.8927_{31}	0.8942_{21}	$\mathbf{0.8943_{14}}$
CIC2018	0.9998	0.9999_{51}	0.9999_{39}	$\mathbf{0.9999_{21}}$
InSDN	0.9996	0.9997_{43}	0.9998_{24}	$\mathbf{0.9998_{12}}$

아래 첨자는 사용된 feature의 개수임.

Decision Tree – InSDN

Phase 0 (P0)

	Prec.	Rec.	F1
BFA*	1	0.99763	0.998814
BOTNET*	0.942308	1	0.970297
DDOS*	1	0.999933	0.999967
DOS	0.999733	0.9996	0.999667
Probe	0.999733	0.9998	0.999767
U2R	0.625	1	0.769231
Web-Attack	0.966667	1	0.983051
normal	0.999805	0.999562	0.999683
Accuracy			0.999697
macro avg	0.941656	0.999566	0.965059
weighted avg	0.999718	0.999697	0.999703

Phase 3 (P3)

	Prec.	Rec.	F1
BFA*	1	0.9976	0.9988
BOTNET*	0.9423	1	0.9702
DDOS*	1	0.9999	0.9999
DOS	0.9996	0.9995	0.9996
Probe	0.9998	0.9997	0.9997*
U2R	1▲0.375	1*	1▲0.2308
Web-Attack	0.9508	1*	0.9747
normal	0.9997	0.9997	0.9997
Accuracy			0.9997
macro avg	0.9865(▲0.045)	0.9995	0.9928(▲0.028)
weighted avg	0.9997	0.9997	0.9997

- Feature 개수 : 79 〉 14
- 전체적으로 거의 완벽한 성능 달성
- **P3**에서 U2R(5)의 precision이 1.0으로 **오탐이 크게 개선됨**

*표시는 P0 결과와 소숫점 6째 자리까지 성능이 동일함.

Decision Tree – InSDN

모델별 결과 분석 (2)

Phase 0 (P0)

Phase 3 (P3)

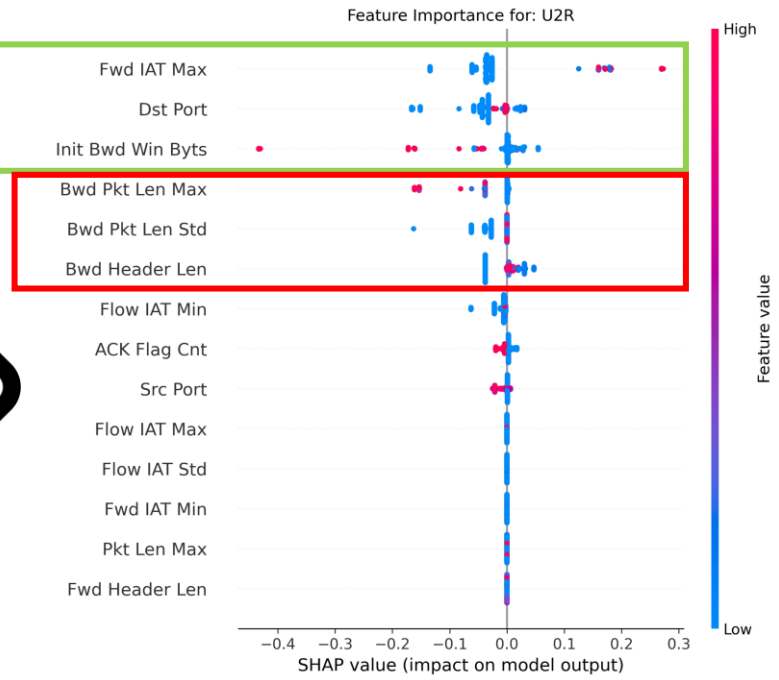

- **U2R의 SHAP 분포 비교**

사용자(User) 권한으로 시스템에 접속한 해커가 시스템 관리자(Root) 권한을 탈취하는 공격 형태

- Feature수가 줄어든 이후에도 **핵심 feature**가 유지됨
- P3에서는 **응답 방향 트래픽 패킷 크기 및 헤더 관련 feature**의 중요도 증가

- 시간 간격과 포트만 보는 것이 아닌 **U2R 트래픽의 응답 패킷 구조까지 반영**하면서 구분력이 증가한 것으로 보임

Decision Tree - Overview

전체적으로 P1에서 성능이 하락한 뒤, 이후 단계에서 회복되는 경향을 보임
CIC2018은 P0, P2, P3에서 동일한 성능을 보여, feature reduction 이후에도 탐지 성능이 안정적으로 유지됨

Decision Tree 모델에서 데이터셋별 phase에 따른 accuracy 변화

	P0	P1	P2	P3
KDD99	0.972	0.9721_{52}	**0.9721_{39}**	0.9698_{29}
UNSW-NB15	0.8796	0.8803_{34}	0.8781_{19}	**0.8844_{12}**
CIC2018	**0.9999**	0.9999_{35}	**0.9999_{18}**	**0.9999_{12}**
InSDN	0.9996	0.9996_{43}	0.9996_{27}	**0.9997_{14}**

아래 첨자는 사용된 feature의 개수임.

SVM – CIC2018

모델별 결과 분석 (3)

Phase 0 (P0)

	Prec.	Rec.	F1
DDOS attack-HOIC*	1	1	1
DDoS attacksLOIC-HTTP*	1	1	1
DoS attacks-Hulk*	0.999933	1	0.999967
Bot*	1	0.999933	0.999967
FTP-BruteForce*	0.999534	1	0.999767
SSH-Bruteforce*	0.999867	1	0.999933
Infiltration	0.999867	0.999933	0.9999
DoS attacks-SlowHTTPTest*	1	1	1
DoS attacks-GoldenEye*	0.999839	0.998956	0.999397
DoS attacks-Slowloris*	0.99457	1	0.997278
DDOS attack-LOIC-UDP*	1	1	1
Brute Force –Web*	0.919355	0.622951	0.742671
Brute Force –XSS*	0.533333	0.927536	0.677249
SQL Injection*	0.454545	0.576923	0.508475
normal	0.999967	0.999433	0.9997
accuracy	0.999297		
macro avg	0.926721	0.941711	0.928287
weighted avg	0.999435	0.999297	0.999312

Phase 1 (P1)

	Prec.	Rec.	F1
DDOS attack-HOIC*	1	1	1
DDoS attacks-LOIC-HTTP*	1	1	1
DoS attacks-Hulk*	0.999933	1	0.999967
Bot*	1	0.999933	0.999967
FTP-BruteForce*	0.999534	1	0.999767
SSH-Bruteforce*	0.999867	1	0.999933
Infiltration	0.999933	1	0.999967
DoS attacks-SlowHTTPTest*	1	1	1
DoS attacks-GoldenEye*	0.999839	0.998956	0.999397
DoS attacks-Slowloris*	0.99457	1	0.997278
DDOS attack-LOIC-UDP*	1	1	1
Brute Force –Web*	0.919355	0.622951	0.742671
Brute Force –XSS*	0.533333	0.927536	0.677249
SQL Injection*	0.454545	0.576923	0.508475
normal	1	0.999467	0.999733
accuracy	0.99931		
macro avg	0.926727	0.941718	0.928294
weighted avg	0.999447	0.99931	0.999324

- Feature 개수 : 118 〉 38
- **P1**에서 **Infiltration**(15,000), **normal**(30,000)의 전체적인 성능 소폭 상승
- 이외의 유형에서는 동일한 성능을 유지

*표시는 P0 결과와 소숫점 6째 자리까지 성능이 동일함.

KWANGWOON UNIVERSITY
CnCS Lab Cryptography & Cyber Security

SVM – CIC2018

모델별 결과 분석 (3)

Phase 0 (P0)

Phase 1 (P1)

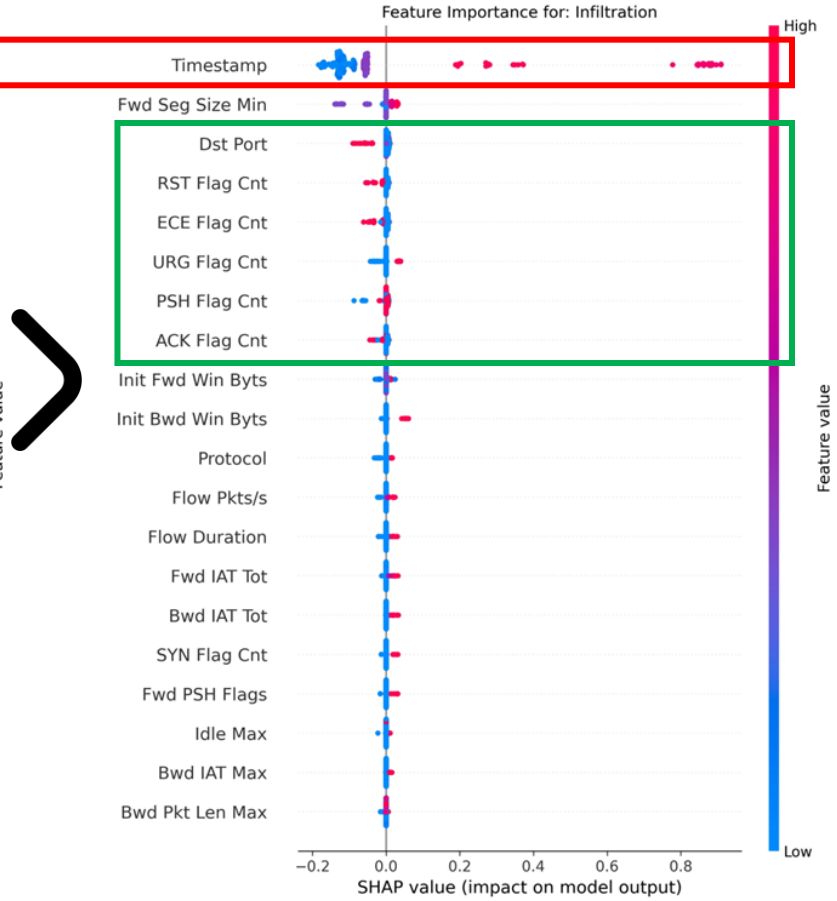

- **Infiltration의 SHAP 분포 비교**

  사이버 공격자가 탐지되지 않고 은밀하게 컴퓨터 네트워크나 시스템에 무단으로 접속하여 잠입하는 행위

- 상위 feature의 변화는 없지만, flag 관련 feature들이 상위권으로 정리되면서 탐지율이 상승한 것으로 보임

- Timestamp의 높은 중요도는 **데이터셋 수집 환경의 시간적 편향일 가능성이 의심됨**

KWANGWOON UNIVERSITY
CnCS Lab

SVM - Overview

Phase가 진행함에 따라 feature의 수가 극단적으로 적어지면 전체 성능이 감소하는 경향을 보임
Feature의 수가 줄어들면서 최적 경계면을 잘 찾지 못하는 것으로 보임

SVM 모델에서 데이터셋별 phase에 따른 accuracy 변화

	P0	P1	P2	P3
KDD99	**0.9846**	0.9795_{36}	0.9752_{25}	0.9766_{20}
UNSW-NB15	0.7925	$\mathbf{0.7931_{25}}$	0.7875_{16}	0.7867_{11}
CIC2018	0.9992	$\mathbf{0.9993_{38}}$	0.9987_{18}	0.9930_{12}
InSDN	**0.9425**	0.9395_{26}	0.9243_{14}	0.9231_{9}

아래 첨자는 사용된 feature의 개수임.

CNN - Overview

모델별 결과 분석 (4)

Phase가 진행될수록 전반적으로 성능이 저하되며 소수 클래스에서는 탐지 실패 발생

CNN 모델에서 데이터셋별 phase에 따른 accuracy 변화

	P0	P1	P2	P3
KDD99	**0.999**	0.9982_{35}	0.9981_{29}	0.998_{23}
UNSW-NB15	0.8632	$\mathbf{0.8633}_{24}$	0.8632_{20}	0.8471_{9}
CIC2018	**0.9995**	0.9995_{40}	0.9995_{28}	0.9976_{14}
InSDN	**0.9989**	0.996_{35}	0.9989	0.9966_{12}

아래 첨자는 사용된 feature의 개수임.

UNSW-NB15 (P1)

	Prec.	Rec.	F1
analysis	0.3931	0.1572	0.2246
backdoor	0.428▲0.228	0.01(▲0.08)	0.0197(▲0.016)
dos	0.2▼0.514	0.0005(▲0.014)	0.0011(▼08027)
exploits	0.7332	0.8384	0.7822
fuzzers	0.595(▼0.07)	0.8869	0.7122(▼0.048)
generic	0.9597	0.8146	0.8812
reconnaissance	0.7577(▲0.016)	0.7417(▼0.049)	0.7496(▲0.07)
shellcode	0.3974▼0.112	0.2737(▼0.002)	0.3241(▼0.034)
worms	0.6666▲0.667	0.0392▲0.039	0.074▲0.074
normal	0.9952	0.9852	0.9901
accuracy	0.8633		
macro avg	0.6126(▲0.036)	0.4747(▼0.003)	0.4759(▲0.003)
weighted avg	0.8553(▼0.012)	0.8633	0.8492

KWANGWOON UNIVERSITY
CnCS Lab

ANN - Overview

가장 Feature Reduction에 민감하게 반응하며, 특히 **UNSW-NB15의 P3에서는 majority class에 대해서도 탐지가 실패함**
전체 feature 조합에 의존하게 학습 구조가 feature 축소로 크게 영향을 받은 것으로 보임

ANN 모델에서 데이터셋별 phase에 따른 accuracy 변화

	P0	P1	P2	P3
KDD99	**0.9989**	0.9983_{39}	0.9982_{32}	0.998_{25}
UNSW-NB15	**0.8685**	0.8674_{27}	0.8667_{16}	0.7637_{7}
CIC2018	**0.9996**	0.9995_{46}	0.9996_{35}	0.9993_{18}
InSDN	**0.9991**	0.9969_{34}	0.9987_{18}	0.9985_{11}

아래 첨자는 사용된 feature의 개수임.

UNSW-NB15 (P3)

	Prec.	Rec.	F1
analysis	0▼0.18	0▼0.682	0▼0.285
backdoor	0▼0.215	0▼0.065	0▼0.101
dos	0▼0.438	0▼0.029	0▼0.054
exploits	0.786▲0.028	0.6237▼0.199	0.6955▼0.093
fuzzers	0.4219▼0.321	0.667▼0.187	0.5169▼0.278
generic	0.5077▼0.432	0.8897▲0.065	0.6465▼0.232
reconnaissance	0▼0.789	0▼0.78	0▼0.785
shellcode	0▼0.481	0▼0.411	0▼0.443
worms*	0	0	0
normal	0.9931	0.9813	0.9871
accuracy	0.7637▼0.105		
macro avg	0.2708▼0.283	0.3161▼0.229	0.2846▼0.227
weighted avg	0.7167▼0.161	0.7637▼0.105	0.7292▼0.136

KNN - Overview

앞선 CNN/ANN에 비해 전체 accuracy는 비교적 안정적으로 유지함
정확도는 높지만, KDD99 UNSW-NB15에서 minority class는 모두 탐지 실패함

ANN 모델에서 데이터셋별 phase에 따른 accuracy 변화

	P0	P1	P2	P3
KDD99	**0.998**	0.998_{57}	0.9986_{36}	0.9975_{28}
UNSW-NB15	0.8442	0.8431_{25}	0.8441_{17}	$\mathbf{0.8449_{15}}$
CIC2018	0.9995	0.9996_{42}	0.9995_{21}	$\mathbf{0.9998_{14}}$
InSDN	**0.9984**	0.9983_{36}	0.9978_{17}	0.9962_{9}

아래 첨자는 사용된 feature의 개수임.

KDD99 (P1)

	Prec.	Rec.	F1
back	0.977341	0.97882	0.97808
buffer_overflow	0.625	0.555556	0.588235
ftp_write	0	0	0
guess_passwd	0.882353	0.9375	0.909091
imap	1	0.5	0.666667
Ipsweep	0.98916	0.975936	0.982503
land	1	1	1
loadmodule	0	0	0
multihop	0	0	0
neptune	0.999534	1	0.999767
nmap	0.891892	0.956522	0.923077
perl	0	0	0
phf	0	0	0
pod	0.987342	0.987342	0.987342
portsweep	0.993421	0.967949	0.980519
rootkit	0	0	0
satan	0.995708	0.972746	0.984093
spy	0.9998	1	0.9999
teardrop	0	0	0
warezclient	0.989899	1	0.994924
warezmaster	0.958065	0.970588	0.964286
normal	0.998116	0.998664	0.99839
accuracy	0.998091		
macro avg	0.649438	0.627346	0.634403
weighted avg	0.997887	0.998091	0.997979

RQ1. 전체 탐지 성능 변화

Feature reduction 이후에도 IDS 모델의 전체 탐지 성능이 어느 수준까지 유지되거나 향상될 수 있는가?

주요 결과

- 적당한 feature reduction은 탐지 성능을 저해하지 않고, **일부 경우 baseline(P0)보다 높은 성능**을 보임
- RF와 DT는 feature 수가 크게 감소했음에도 전체 성능이 유지되거나 향상됨
- SVM, CNN, ANN, KNN은 feature reduction에 상대적으로 민감하게 반응함

결과 해석

- **트리 기반 모델**은 feature가 감소함에 따라 **핵심 feature에 더 집중되어 탐지 정밀도가 향상된 것**으로 해석됨
- **신경망 기반 모델**은 입력 feature 공간이 축소되면서 **공격 유형을 구분하기 위한 표현 능력이 감소**함

RQ2. 소수 클래스 영향

Feature reduction 과정에서 데이터 수가 극히 적은 소수 클래스(Minority class)의 탐지 성능은 어떻게 변화하는가?

성능 저하 사례

- CNN (InSDN): U2R F1-score가 1.0(P0) → 0.0(P3)으로 감소
- ANN (UNSW-NB15) : 소수 클래스 (reconnaissance, analysis, dos)에서 탐지 실패 발생
- ANN (KDD99): ftp_write, perl, phf, rootkit 등 소수 클래스 성능 급락

성능 향상 사례

- RF (KDD99): P3에서 기존에 탐지하지 못했던 loadmodule 탐지 성공
- CNN (UNSW-NB15): P1에서 worms 탐지 성능 향상 (0 → 0.66)
- KNN (UNSW-NB15): worms 정밀도 0.33(P0) → 1.0(P3)으로 개선

결론 및 향후 연구

결론

- 본 연구는 SHAP 기반 feature importance를 활용하여 IDS에서 사용되는 주요 모델의 **핵심 feature를 식별하고, 단계적 feature reductio이 탐지 성능에 미치는 영향을 분석함**
- 트리 기반 모델은 feature reduction 이후에도 안정적인 성능을 유지하여 비교적 강건한 특성을 보임
- 반면 신경망 기반 모델은 feature reduction에 민감하게 반응하여 성능 저하가 크게 나타남

향후 연구

- 소수 클래스 성능 저하 문제를 해결하기 위해, **공격 유형별 핵심 feature를 독립적으로 식별하고 보존하는 reduction 기법 연구**
- 탐지 성능뿐만 아니라 feature reduction에 따른 학습 시간, 추론 시간, 메모리 사용량 감소 효과를 포함한 분석

자료 출처

[1] IBM Think, 블랙박스 AI란?, https://www.ibm.com/kr-ko/think/topics/black-box-ai
[2] IBM Think, 설명 가능한 AI(XAI)란 무엇인가요?, https://www.ibm.com/kr-ko/think/topics/explainable-ai
[3] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in neural information processing systems*, *30*.
[4] 분류 모델 성능 평가 지표(Accuracy, Precision, Recall, F1 score 등), https://white-joy.tistory.com/9
[5] confusion matrix, https://statisticsbyjim.com/glossary/confusion-matrix/
[6] SK 쉴더스, XSS 공격 vs SQL 인젝션, 차이점과 예방 가이드, https://www.skshieldus.com/security-insights/trends/xss-sql-injection-comparison

이미지/아이콘 출처

[1] Flaticon, https://www.flaticon.com/kr/search?word=%EB%AC%BC%EC%9D%8C%ED%91%9C&type=uicon

한국정보보호학회
Korea Institute of Information Security & Cryptology

감사합니다.

광운대학교 컴퓨터공학과 우나륜 (mercy1234@kw.ac.kr)

KWANGWOON UNIVERSITY

CnCS Lab
Cryptography & Cyber Security