SHAP 기반 Feature Importance을 이용한 IDS Feature Reduction과 탐지 성능 영향 분석

우나륜*, 유지현**

*광운대학교 (대학원생) **광운대학교 (교수)

SHAP-Based Feature Importance for IDS: Impact of Feature Reduction on Detection Performance

Naryun Woo*, Jihyeon Ryu**

*Kwangwoon University(Graduate student) **Kwangwoon University(Professor)

요 약

본 연구에서는 SHAP 기반 feature importance를 이용하여 침입탐지시스템(IDS)의 주요 feature를 식별하고, 단계적 feature reduction에 따른 탐지 성능 변화를 분석하였다. 실험 결과, RF와 DT와 같은 트리 기반 모델은 feature reduction 이후에도 전체 탐지 성능이 비교적 안정적으로 유지되었으며, 일부 데이터셋에서는 오히려 성능이 향상되었다. 반면 SVM, CNN, ANN 등 신경망 기반 모델은 feature reduction에 민감하게 반응하여 성능 저하가 크게 나타났다. 또한 전체 accuracy는 유지되더라도 특정 공격 유형의 탐지 성능이 감소하는 현상이 관찰되었으며, 이는 해당 공격 유형에 중요한 feature가 제거되었기 때문으로 분석되었다. 본 연구는 IDS에서 모든 feature를 사용하는 것이 반드시 높은 성능으로 이어지는 것은 아니며, 일부 핵심 feature만으로도 전체 탐지 성능을 유지할 수 있음을 보여준다. 또한 IDS에서의 feature selection은 공격 유형별 특성을 반영하여 클래스별 핵심 feature를 보존하는 방향으로 수행될 필요가 있음을 시사한다.

I. 서론

네트워크 환경의 지능화 및 복잡화와 사이버 공격의 양상이 다양해짐에 따라, 이를 탐지하고 방어하기 위한 침입탐지시스템(Intrusion Detection System, IDS)의 중요성이 증가하고 있다. 이에 따라 최근 연구에서는 자동화된 탐지와 복잡한 트래픽 패턴을 학습하기 위해 Random Forest(RF), Decision Tree(DT), Neural Network(NN), 등 다양한 AI 기법이 활용되고 있다.

하지만, AI 기반 IDS는 높은 탐지 성능에도 불구하고 몇 가지 한계를 가진다. 첫째, 모델이 black-box 형태로 동작함에 따라 특정 트래픽을 공격으로 판단한 근거를 설명하기 어렵다. 둘째, IDS 데이터셋은 많은 수의 feature로 구성되어 있으며, 대부분의 연구는 이를 그대로 학습에 사용한다. 이는 모델 복잡도와 연산량을 증가시키며, 효율적인 탐지를 저해한다.

위 문제를 해결하기 위해 최근에는 설명 가능한 인공지능(eXplainable AI, XAI)을 적용하여 모델의 판단 근거를 시각화하고 feature별 기여도를 분석하여 설명을 제공하는 연구가 이뤄지고 있다 [1,2]. 그러나 기존 연구들은 주로 XAI 결과 해석에 초점을 두고 있으며, 이를 기반으로 중요도가 낮은 feature를 제거했을 때 발생하는 성능 변화를 분석한 연구는 상대적으로 부족한 실정이다.

따라서 본 연구에서는 SHAP 기법을 활용하여 feature별 중요도를 산출하고, 이를 기반으로 단계적인 feature reduction을 수행하여 IDS 성능 변화를 분석한다. 본 연구를 통해 도출하고자 하는 Research Question은 다음과 같다.

- RQ1. Feature reduction 이후에도 IDS 모델의 전체 탐지 성능은 어느 수준까지 유지되거나 향상될 수 있는가?
- RQ2. Feature reduction 과정에서 데이터 수가 적은 클래스의 탐지 성능은 어떻게 변화하는가?

II. SHapely Additive exPlanation

SHAP(SHapley Additive exPlanation)은 협동 게임 이론의 Shapley Value를 기반으로 모델의 예측 결과를 설명하는 기법이다 [3]. 특정 feature i의 기여도를 나타내는 Shapley Value $\phi_i(v)$는 전체 feature 집합 N에서 해당 feature가 포함된 하위 집합($S \cup i$)과 포함되지 않은 하위 집합(S)의 예측치 변화량을 가중 평균하여 산출한다.

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(n-|S|-1)!}{n!} [v(S \cup i) - v(S)]$$

[수식 1] Shapely Value 산출식

III. 연구 방법

3.1 실험 절차

본 연구는 [그림 1]과 같이 데이터 전처리, 모델 평가, SHAP 기반 feature selection의 단계로 구성된다. 먼저 데이터셋에서 필요한

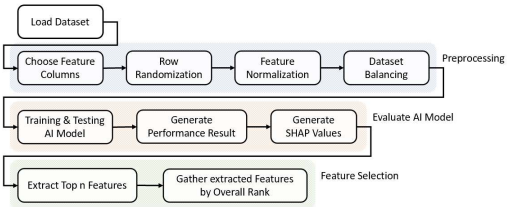

[그림 1] 전체 실험 절차 및 SHAP 기반 feature reduction 실험 흐름도

feature 열을 선택한 뒤, 정규화와 균형화 과정을 수행하여 학습용 데이터를 구성한다. 이후 각 모델을 학습하고, 성능 지표와 함께 SHAP value를 산출한다.

이후 SHAP 기반 중요도를 이용하여 단계적 feature reduction을 수행하였다. P0에서는 전체 feature를 사용하여 학습한 뒤, 클래스별 상위 20개 feature를 추출하여 P1의 입력 feature subset을 구성하였다. 다음 단계에서 사용할 feature subset을 구성하였다. 같은 방식으로 P1에서는 상위 10개, P2에서는 상위 5개를 클래스별로 추출하였다.

3.2. 데이터셋 및 실험 모델

다양한 네트워크 환경과 공격 시나리오를 실험하기 위해 4종의 공개 데이터셋(KDD99 [4], UNSW-NB15 [5], CIC2018 [6], InSDN [7])과 분류 모델 RF, DT, SVM, CNN, ANN, KNN의 6종을 선정하였다.

[표 1] 데이터셋별 전체 feature 수와 클래스(공격유형+정상) 개수

	[4]	[5]	[6]	[7]
Feature	118	38	79	79
Class	22	10	7	14

3.4 평가 지표

모델의 탐지 성능을 평가하기 위해 Accuracy, Precision, Recall, F1-score를 평가지표로 활활용하였다. 또한, 클래스별 데이터 개수 불균형 문제를 고려하여 각 지표의 가중 평균(Weighted average)도 함께 고려하였다.

IV. 실험 결과 및 해석

4.1. Feature reduction에 따른 모델별 성능 변화

[표 2-7]는 각 모델의 데이터셋별 feature reduction 단계(P0 - P3)에 따른 accuracy 변화를 나타낸다. 이때 각 수치의 아래 첨자는 각 단계에서 사용된 feature 수를 의미한다. 또한 [그림 2-5]는 성성능 변화가 유의미하게 나타난 부분만을 선별하여 P0대비 성능 증감 추이를 시각적으로 나타낸 것이다.

먼저, RF 모델의 경우 feature reduction 이후에도 전체 성능이 거의 유지되거나 오히려 향상되는 결과가 나타났다. 특히, KDD99의 P3에서는 이전 단계에서 탐지하지 못했던 loadmodule을 탐지하는 결과가 나타났다 [그림 2]. 또한, CIC2018의 P3에서는 SQL Injection의 precision이 24.13%p 개선되었다 [그림 4(a)].

DT 모델 역시 feature reduction 이후에도 전체 성능이 비교적 안정적으로 유지되는 경향을 보였다. InSDN의 P3은 U2R에 대한 precision이 0.625에서 1.0으로 대폭 향상되었다 [그림 3]. 특히, CIC2018의 P3는 feature 수가 84.4% 감소하였음에도 모든 유형에서 P0와 동일한 성능을 보였다 [그림 4(b)].

[표 2] RF 모델에서 phase에 따른 accuracy 변화

	P0	P1	P2	P3
[4]	0.9988	0.999_{52}	0.999_{48}	$\mathbf{0.9989}_{37}$
[5]	0.8923	0.8927_{31}	0.8942_{21}	$\mathbf{0.8943}_{14}$
[6]	0.9998	0.9999_{51}	0.9999_{39}	$\mathbf{0.9999}_{21}$
[7]	0.9996	0.9997_{43}	0.9998_{24}	$\mathbf{0.9998}_{12}$

	Prec.	Rec.	F1
back*	1	0.9984	0.9992
buffer_overflow*	0.875	0.7777	0.8235
ftp_write*	0	0	0
guess_passwd*	1	0.9375	0.9677
imap*	1	1	1
ipsweep	0.9945	0.9812	0.9878
land*	1	1	1
loadmodule	1▲1	0.333▲0.333	0.5▲0.5
multihop*	1	0.5	0.6666
neptune*	1	1	1
nmap	0.9571(▼0.138)	0.971*	0.964
perl*	1	1	1
phf*	1	1	1
pod*	1	0.9873	0.9936
portsweep	1*	0.9903	0.9951
rootkit*	0	0	0
satan	1*	0.9895	0.9947
spy*	1	0.9999	0.9999
teardrop*	0	0	0
warezclient*	1	1	1
warezmaster	0.9074▲0.159	0.9934*	0.9485(▲0.009)
normal	0.999	0.9989	0.9989
accuracy			0.9989
macro avg	0.8515 (▲0.0456)	0.7935 (▲0.0147)	0.8109 (▲0.0236)
weighted avg	0.9988	0.9989	0.9988

[그림 2] KDD99 데이터셋 기반 RF모델의 Phase 3 성능 평가 (118 → 37 축소)

*(*표시는 P0 결과와 소숫점 6째 자리까지 성능이 동일함.)*

[표 3] DT 모델에서 phase에 따른 accuracy 변화

	P0	P1	P2	P3
[4]	0.972	0.9721_{52}	$\mathbf{0.9721}_{39}$	0.9698_{29}
[5]	0.8796	0.8803_{34}	0.8781_{19}	$\mathbf{0.8844}_{12}$
[6]	**0.9999**	0.9999_{35}	$\mathbf{0.9999}_{18}$	$\mathbf{0.9999}_{12}$
[7]	0.9996	0.9996_{43}	0.9996_{27}	$\mathbf{0.9997}_{14}$

	Prec.	Rec.	F1
BFA*	1	0.9976	0.9988
BOTNET*	0.9423	1	0.9702
DDOS*	1	0.9999	0.9999
DOS	0.9996	0.9995	0.9996
Probe	0.9998	0.9997	0.9997*
U2R	1▲0.375	1*	1▲0.2308
Web-Attack	0.9508	1*	0.9747
normal	0.9997	0.9997	0.9997
Accuracy			0.9997
macro avg	0.9865(▲0.045)	0.9995	0.9928(▲0.028)
weighted avg	0.9997	0.9997	0.9997

[그림 3] InSDN 데이터셋 기반 DT모델의 Phase 3 성능 평가 (79 → 14 축소)

SVM 모델의 경우 전반적으로 feature reduction이 진행될수록 성능이 소폭 감소하였다. CIC2018의 P1은 P0보다 향상된 성능을 보였으나 [그림 4(c)], 이후 phase가 진행되면서 성능이 감소하였다. 그러나 feature 수 감소 폭을 함께 고려하면 성능 저하는 최대 약 1.94%p 이내로 비교적 제한적인 수준에 머물었다. 특히 InSDN의 P3에서는 P0 대비 weighted F1-score는 약 1.66%p 감소하였다. 한편, 이때 BOTNET 유형

	Prec.	Rec.	F1
DDOS attack-HOIC	1	1	1
DDoS attacks-LOIC-HTTP*	1	1	1
DoS attacks-Hulk*	1	1	1
Bot*	1	1	1
FTP-BruteForce*	1	1	1
SSH-Bruteforce*	1	1	1
Infiltration*	0.9999	1	0.9999
DoS attacks-SlowHTTPTest*	1	1	1
DoS attacks-GoldenEye*	1	1	1
DoS attacks-Slowloris	1*	1	1
DDOS attack-LOIC-UDP*	1	1	1
Brute Force –Web	0.9781▼0.0102	0.9781▲0.0492	0.9781▲0.0204
Brute Force –XSS*	1	0.9275	0.9624
SQL Injection	0.8275▲0.1609	0.9230▼0.077	0.8727▲0.0727
Normal	0.9999	1*	0.9999
accuracy			0.9999
macro avg	0.9870▲0.0101	0.9885▼0.0018	0.9875▲0.0062
weighted avg	0.9999	0.9999	0.9999

(a) Random Forest (P3)

	Prec.	Rec.	F1
DDOS attack-HOIC*	1	1	1
DDoS attacks-LOIC-HTTP*	1	1	1
DoS attacks-Hulk*	1	1	1
Bot*	1	1	1
FTP-BruteForce*	1	1	1
SSH-Bruteforce*	1	1	1
Infiltration*	1	1	1
DoS attacks-SlowHTTPTest*	1	1	1
DoS attacks-GoldenEye*	1	1	1
DoS attacks-Slowloris*	1	1	1
DDOS attack-LOIC-UDP*	1	1	1
Brute Force –Web*	0.994565	1	0.997275
Brute Force –XSS*	1	0.985507	0.992701
SQL Injection*	0.961538	0.961538	0.961538
Normal*	1	1	1
accuracy			0.999988
macro avg	0.997074	0.99647	0.996768
weighted avg	0.999988	0.999988	0.999988

(b) Decision Tree (P3)

	Prec.	Rec.	F1
DDOS attack-HOIC*	1	1	1
DDoS attacks-LOIC-HTTP*	1	1	1
DoS attacks-Hulk*	0.999933	1	0.999967
Bot*	1	0.999933	0.999967
FTP-BruteForce*	0.999534	1	0.999767
SSH-Bruteforce*	0.999867	1	0.999933
Infiltration	0.999933	1	0.999967
DoS attacks-SlowHTTPTest*	1	1	1
DoS attacks-GoldenEye*	0.999839	0.998956	0.999397
DoS attacks-Slowloris*	0.99457	1	0.997278
DDOS attack-LOIC-UDP*	1	1	1
Brute Force –Web*	0.919355	0.622951	0.742671
Brute Force –XSS*	0.533333	0.927536	0.677249
SQL Injection*	0.454545	0.576923	0.508475
normal	1	0.999467	0.999733
accuracy	0.99931		
macro avg	0.926727	0.941718	0.928294
weighted avg	0.999447	0.99931	0.999324

(c) SVM (P1)

[그림 4] CIC2018 데이터셋 기반 RF, DT, SVM 모델의 성능 분석 (79 → 21/12/9 축소)

은 recall 1.0을 유지한 상태에서 precision이 56.98%p 향상되었다. 이는 SVM에서도 소수의 핵심 feature만으로 전체 탐지 성능을 상당 부분 유지할 수 있음을 시사한다.

[표 4] SVM 모델에서 phase에 따른 accuracy 변화

	P0	P1	P2	P3
[4]	**0.9846**	0.9795_{36}	0.9752_{25}	0.9766_{20}
[5]	0.7925	$\mathbf{0.7931}_{25}$	0.7875_{16}	0.7867_{11}
[6]	0.9992	$\mathbf{0.9993}_{38}$	0.9987_{18}	0.9930_{12}
[7]	**0.9425**	0.9395_{26}	0.9243_{14}	0.9231_{9}

CNN 모델의 경우, KDD99와 InSDN에서는 phase가 진행됨에 따라 precision, recall, F1-score가 전반적으로 약 0.19~0.29 수준 감소하였다 특히, UNSW-NB15의 P1에서는 24개의 feature만으로 P0에서 탐지하지 못했던 worms 유형을 탐지하였으나[그림 5(a)], 이후 P3에서는 backdoor와 dos 유형의 F1-score가 0으로 탐지에 실패하였다. 또한 CIC2018에서는 SQL Injection의 precision이 약 0.1 향상되었으나, 전체 성능은 phase에 따라 점진적으로 감소하는 경향을 보였다.

[표 5] CNN 모델에서 phase에 따른 accuracy 변화

	P0	P1	P2	P3
[4]	**0.999**	0.9982_{35}	0.9981_{29}	0.998_{23}
[5]	0.8632	$\mathbf{0.8633}_{24}$	0.8632_{20}	0.8471_{9}
[6]	**0.9995**	0.9995_{40}	0.9995_{28}	0.9976_{14}
[7]	**0.9989**	0.996_{35}	0.998918	0.9966_{12}

ANN 모델은 feature reduction에 가장 민감하게 반응하였다. KDD99의 P3에서는 테스트 데이터 수가 3개 이하인 공격유형(ftp_write, loadmodule, perl, phf, rootkit)에서 F1-score가 0으로 탐지에 실패하였다. InSDN에서도 U2R 유형을 P1 이후 더 이상 탐지하지 못하였다. UNSW-NB15의 P3에서 가장 성능 저하가 두드러졌으며, 특히 reconnaissance 유형은 테스트 데이터 수가 4,007개임에도 탐지에 실패하였다[그림 5(b)].

[표 6] ANN 모델에서 phase에 따른 accuracy 변화

	P0	P1	P2	P3
[4]	**0.9989**	0.9983_{39}	0.9982_{32}	0.998_{25}
[5]	**0.8685**	0.8674_{27}	0.8667_{16}	0.7637_{7}
[6]	**0.9996**	0.9995_{46}	0.9996_{35}	0.9993_{18}
[7]	**0.9991**	0.9969_{34}	0.9987_{18}	0.9985_{11}

마지막으로, KNN 모델은 KDD99와 InSDN에서 phase가 진행될수록 전반적으로 성능이 감소였다. 반면, UNSW-NB15의 P3에서는 15개의 feature만으로도 전체 성능이 비교적 안정적으로 유지되었으며 [그림 5(c)], 특히 worms 유형의 precision이 기존 0.33에서 1.0으로 크게 향상되었다. CIC2018의 P2에서는 전체 성능이 일시적으로 크게 저하되었다가 P3에서 일부 회복되는 양상이 나타났다. 다만 SQL Injection의 precision이 약 0.1 수준 감소하여 전체 precision을 소폭 감소시키는 요인으로 작용하였다.

[표 7] KNN 모델에서 phase에 따른 accuracy 변화

	P0	P1	P2	P3
[4]	**0.998**	0.998_{57}	0.9986_{36}	0.9975_{28}
[5]	0.8442	0.8431_{25}	0.8441_{17}	$\mathbf{0.8449}_{15}$
[6]	0.9995	0.9996_{42}	0.9995_{21}	$\mathbf{0.9998}_{14}$
[7]	**0.9984**	0.9983_{36}	0.9978_{17}	0.9962_{9}

4.2. RQ1. Feature Reduction 이후 성능 변화 분석

본 연구의 실험 결과, 적절한 feature reduction은 모델의 탐지 성능을 저해하지 않을 뿐만 아니라, 오히려 Baseline(P0)보다 우수한 성능을 도출하는 경우도 확인되었다. 특히 RF와 DT 모델은 feature 수가 상당히 축소되었음에도, 전체 성능 지표가 거의 유지되거나 향상되는 결과를 보였다. 이는 불필요하거나 중복되는 feature가 제거되면서 모델이 실제로 중요한 feature에 더 집중하게 되었고, 그 결과 과적합이 감소하고 탐지 정밀도가 향상된 것으로 해석된다.

반면 SVM, CNN, ANN, KNN 모델은 feature reduction에 상대적으로 민감하게 반응하여 전반적인 성능 저하와 특정 공격 유형에 대한 탐지 실패가 관찰되었다. 특히 신경망 기반 모델의 경우 입력 feature 공간이 축소되면서 공격 유형을 구분하기 위한 특징 표현 능력이 감소하여 성능 저하로 이어진 것으로 보인다.

따라서 feature reduction 이후에도 모델과 데이터셋에 따라 전체 탐지 성능은 상당 부분 유지될 수 있으며, 일부는 성능 향상도 가능함을 확인하였다. 이는 IDS에서 모든 feature를 사용하는 것이 반드시 높은 성능으로 이어지는 것은 아니며, 일부 핵심 feature만으로도 전체 탐지 성능을 유지할 수 있음을 의미한다.

4.3. RQ2. 소수 클래스 탐지 성능 변화 분석

IDS 데이터셋 내 U2R, Reconnaissance, Shellcode 등의 클래스는 데이터 수는 적지만 권한 탈취, 내부 침투, 취약점 악용과 같이 파급력이 큰 공격을 포함하므로, feature reduction이 이들 클래스의 탐지 성능에 미치는 영향을 분석

	Prec.	Rec.	F1
analysis	0.3931	0.1572	0.2246
backdoor	0.428▲0.228	0.01(▲0.08)	0.0197(▲0.016)
dos	0.2▼0.514	0.0005(▲0.014)	0.0011(▼08027)
exploits	0.7332	0.8384	0.7822
fuzzers	0.595(▼0.07)	0.8869	0.7122(▼0.048)
generic	0.9597	0.8146	0.8812
reconnaissance	0.7577(▲0.016)	0.7417(▼0.049)	0.7496(▲0.07)
shellcode	0.3974▼0.112	0.2737(▼0.002)	0.3241(▼0.034)
worms	0.6666▲0.667	0.0392▲0.039	0.074▲0.074
normal	0.9952	0.9852	0.9901
accuracy	0.8633		
macro avg	0.6126(▲0.036)	0.4747(▼0.003)	0.4759(▲0.003)
weighted avg	0.8553(▼0.012)	0.8633	0.8492

(a) CNN (P1)

	Prec.	Rec.	F1
analysis	0▼0.18	0▼0.682	0▼0.285
backdoor	0▼0.215	0▼0.065	0▼0.101
dos	0▼0.438	0▼0.029	0▼0.054
exploits	0.786▲0.028	0.6237▼0.199	0.6955▼0.093
fuzzers	0.4219▼0.321	0.667▼0.187	0.5169▼0.278
generic	0.5077▼0.432	0.8897▲0.065	0.6465▼0.232
reconnaissance	0▼0.789	0▼0.78	0▼0.785
shellcode	0▼0.481	0▼0.411	0▼0.443
worms*	0	0	0
normal	0.9931	0.9813	0.9871
accuracy	0.7637▼0.105		
macro avg	0.2708▼0.283	0.3161▼0.229	0.2846▼0.227
weighted avg	0.7167▼0.161	0.7637▼0.105	0.7292▼0.136

(b) ANN (P3)

	Prec.	Rec.	F1
analysis	0.0641	0.1038	0.0793
backdoor	0.0436	0.0436	0.0436
dos	0.1145	0.0558	0.0751
exploits	0.7017	0.7922	0.7442
fuzzers	0.7481	0.7559	0.7520
generic	0.9337	0.8108	0.8679
reconnaissance	0.6302	0.7559	0.6873
shellcode	0.5606	0.2141	0.3099
worms	1▲0.667	0.0196*	0.0384
normal	0.9916	0.9871	0.9894
accuracy	0.8449		
macro avg	0.5788(▲0.071)	0.4539(▲0.007)	0.4587(▲0.007)
weighted avg	0.8457	0.8449	0.8427

(c) KNN (P3)

[그림 5] UNSW-NB15 데이터셋 기반 CNN, ANN, KNN의 성능 분석 (38 → 24/7/15 축소)

하는 것은 중요하다. 실험 결과, feature reduction은 소수 클래스 탐지 성능에 큰 영향을 미쳤으며, 경우에 따라 성능 향상과 성능 저하가 모두 나타났다.

대표적으로, CNN의 InSDN에서 P0에서 F1-score 1.0이던 U2R이 P3에서 0으로 감소하였다. 이는 Pwd IAT Max와 BwdPkts/s feature가 제거되면서 해당 공격을 구분하는 핵심 정보가 손실되었기 때문으로 해석된다. 또한 ANN의 UNSW-NB15에서는 상대적으로 데이터의 수가 많은 reconnaissance, analysis, backdoor, dos이 탐지 실패 수준으로 저하되었는데, 이는 ct_dst_sport_ltm, ct_srv_dst와 같은 주요 feature가 제거되었기 때문으로 확인된다. KDD99의 ftp_write, perl, phf, rootkit 및 InSDN의 U2R 역시 탐지 성능이 급격히 저하되었다.

반면 성능 향상 사례도 확인되었다. RF의 KDD99에서는 P3에서 이전에 탐지하지 못했던 loadmodule을 탐지하였으며, 이 과정에서 lnum_file_creation의 상대적 중요도가 증가한 것을 확인하였다. 또한 UNSW-NB15의 경우, CNN의 P1에서 worms 탐지 성능이 향상되었고, KNN의 P3에서도 precision이 0.33에서 1.0으로 개선되었다. 이는 feature reduction이 불필요한 feature를 제거하여 중요한 feature의 영향력을 상대적으로 증가시킬 수 있음을 보여준다.

결과적으로, IDS에서의 feature 선택은 XAI 기반 중요도만을 기준으로 일괄적으로 수행되기보다, 공격 유형별 특성을 반영하는 방향으로 이루어질 필요가 있음을 시사한다.

V. 결론 및 향후연구

본 연구에서는 SHAP 기반 feature importance를 이용하여 IDS 모델의 주요 feature를 식별하고, feature 수를 단계적으로 감소시키면서 성능 변화를 분석하였다. 실험 결과, 트리 기반 모델은 feature reduction 이후에도 안정적인 성능을 유지하여 비교적 강건한 특성을 가진다는 것을 확인할 수 있었다. 반면, 신경망 기반 모델은 feature reduction에 민감하게 반응하여 성능 저하가 크게 나타났다. 또한 일부 데이터셋에서는 feature 수가 감소했음에도 불구하고 성능이 거의 유지되거나 오히려 향상되는 결과가 나타났다.

한편, feature reduction 과정에서 전체 accuracy는 유지되더라도 특정 공격 유형의 탐지 성능이 저하되는 현상이 관찰되었다. 이는 SHAP 기반 feature reduction 과정에서 해당 공격 유형을 구분하는 데 중요한 feature가 제거된 것으로 나타났다.

향후 연구에서는 소수 클래스의 탐지 성능 저하 문제를 해결하기 위해, 공격 유형별 핵심 feature를 독립적으로 식별하고, 이를 보존하여 reduction을 수행하는 기법을 연구할 예정이다. 또한 SHAP 외에도 다양한 XAI 기법을 함께 적용하여 기여도를 종합적으로 분석함으로써, 보다 안정적이고 일반화 가능한 최적의 프레임워크를 제안하고자 한다.

Acknowledgment

본 연구성과물은 2026년도 정부(교육부)의 재원으로 한국연구재단의 지원을 받아 수행된 기초연구사업임(RS-2025-25403069).

[참고문헌]

[1] E. Lanfer, S. Sylvester, N. Aschenbruck, & M. Atzmueller, “Leveraging explainable ai methods towards identifying classification issues on ids datasets”, IEEE 48th Conference on Local Computer Networks, Oct. 2023.

[2] S. Shoukat., T. Gao., D. Javeed, M.S. Saeed, & M. Adil, “Trust my IDS: An explainable AI integrated deep learning-based transparent threat detection system for industrial networks”, Computers & Security, 2025.

[3] S.M. Lundberg & S.I. Lee, “A unified approach to interpreting model predictions”, Advances in neural information processing systems, 2017.

[4] R. Lippmann, J.W. Haines, D.J. Fried, J. Korba, & K. Das, “Analysis and results of the 1999 DARPA off-line intrusion detection evaluation”, Proc. Int. Workshop Recent Advances in Intrusion Detection, Oct. 2000.

[5] N. Moustafa & J. Slay, “UNSW-NB15: A comprehensive data set for network intrusion detection systems”, Proc. Mil. Commun. Inf. Syst. Conf., Nov. 2015.

[6] I. Sharafaldin, A.H. Lashkari, & A.A. Ghorbani, “Toward generating a new intrusion detection dataset and intrusion traffic characterization”, Proc. Int. Conf. Inf. Syst. Secur. Privacy, 2018.

[7] M.S. Elsayed, N.A. Le-Khac, & A.D. Jurcut, “InSDN: A novel SDN intrusion dataset”, IEEE Access, 2020.